



兰州大学

本科毕业论文（设计）

论文题目（中文） 基于不同距离计算的图像聚类分析

论文题目（英文） Image Clustering Analysis Based on Different
Distance Calculations

学生姓名 李嘉康

指导教师 路永钢

学 院 信息科学与工程学院

专 业 计算机科学与技术

年 级 2019 级

兰州大学教务处

诚信责任书

本人郑重声明：本人所提交的毕业论文（设计），是在导师的指导下独立进行研究所取得的成果。毕业论文（设计）中凡引用他人已经发表或未发表的成果、数据、观点等，均已明确注明出处。除文中已经注明引用的内容外，不包含任何其他个人、集体已经发表或未发表的论文。

本声明的法律责任由本人承担。

论文作者签名：_____

日期：2023/4/19

关于毕业论文（设计）使用授权的声明

本人在导师指导下所完成的论文及相关的职务作品，知识产权归属兰州大学。本人完全了解兰州大学有关保存、使用毕业论文（设计）的规定，同意学校保存或向国家有关部门或机构送交论文的纸质版和电子版，允许论文被查阅和借阅；本人授权兰州大学可以将本毕业论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用任何复制手段保存和汇编本毕业论文（设计）。本人离校后发表、使用毕业论文（设计）或与该毕业论文（设计）直接相关的学术论文或成果时，第一署名单位仍然为兰州大学。

本毕业论文（设计）研究内容：

☒可以公开

☐不宜公开，已在学位办公室办理保密申请，解密后适用本授权书。

（请在以上选项内选择其中一项打“√”）

论文作者签名：_____

导师签名：_____

日期：2023/4/19

日期：2023/4/19

基于不同距离计算的图像聚类分析

中文摘要

摘要：近年来传统机器学习聚类方法应用于图像聚类上越来越热门，但是缺少相关距离计算方式对结果影响的讨论，同时因为均值漂移算法是基于坐标（高维空间）的聚类算法，因此也很少有对于均值漂移算法应用于图像聚类相关的研究。值得一提的是，随着深度学习的火爆，深度学习方法运用在图像聚类上也越来越成熟，但是与传统机器学习方法结合在一起的讨论也相对很少。基于以上情况，本文着重讨论 K-均值算法，均值漂移算法，中心点偏移算法在不同距离方式计算下的效果，同时讨论以上算法结合深度学习方法深度残差神经网络后结合不同距离计算方式的效果。

关键词：K-均值算法；均值漂移算法；中心点偏移算法；图像聚类；深度残差神经网络

Image Clustering Analysis Based on Different Distance Calculations

Abstract

In recent years, traditional machine learning clustering methods have become increasingly popular in image clustering. However, there is a lack of discussion on how distance calculation methods affect the results. Additionally, since Mean-Shift is a clustering algorithm based on coordinates (high-dimensional space), there has been little research on its application in image clustering. It is worth noting that with the popularity of deep learning, deep learning methods have also become more mature in image clustering. However, there has been relatively little discussion on combining traditional machine learning methods with deep learning methods. Given these circumstances, this paper focuses on discussing the performance of K-Means, Mean-Shift, and Medoid-Shift under different distance calculation methods. It also discusses the effect of combining these algorithms with the deep learning method ResNet under different distance calculation methods.

Keywords: K-Means; Mean-Shift; Medoid-Shift; Image Clustering.

目 录

中文摘要	II
英文摘要	III
图/表目录	V
第一章 绪论	1
1.1 研究背景以及选题意义	1
1.2 主要研究内容	2
第二章 相关方法介绍	2
2.1 K-均值算法原理介绍	2
2.2 均值漂移算法和中心点偏移算法原理介绍	3
2.2.1 均值漂移算法原理介绍	3
2.2.2 中心点偏移算法原理介绍	5
2.3 深度残差网络算法原理介绍	6
2.4 深度残差网络和聚类算法结合原理介绍	7
第三章 问题定义及实验结果分析	9
3.1 问题基本定义	9
3.2 评价指标选取	9
3.3 数据集介绍	9
3.4 实验设置以及参数介绍	10
3.5 基于余弦，欧式距离的算法结果比较	10
3.5.1 参数设置	10
3.5.2 实验结果展示以及分析	10
3.6 基于深度残差网络算法特征提取后的余弦，欧式距离的算法结果比较	12
3.6.1 参数设置与实验结果	12
3.6.2 讨论分析	13
第四章 总结与展望	14
参考文献	15
致谢	16

图/表 目 录

图一 K-均值迭代图.....	3
图二 均值漂移算法迭代过程.....	5
图三 中心点偏移算法和均值漂移算法差别.....	6
图四 残差学习过程.....	7
图五 K-均值欧几里得距离聚类结果.....	11
图六 均值漂移算法欧几里得距离聚类结果.....	11
图七 中心点偏移算法欧几里得距离聚类结果.....	11
表一 欧几里得距离实验参数设置以及归一化互信息值.....	12
表二 余弦距离实验参数设置以及归一化互信息值.....	12
表三 深度残差网络算法中欧几里得距离实验参数设置及归一化值.....	13
表四 深度残差网络算法中余弦距离实验参数设置及归一化互信息值....	13

引 言

为了解决摘要中所引述的问题，本篇文章着重讨论算法在不同距离计算方式下图像聚类的效果，以及结合深度残差网络算法之后的效果。

为了更好探讨其效果，本文采用动物数据集作为实验图像数据。由于已知动物具体分类，因此采用了归一化互信息（归一化互信息）来评价聚类的具体效果。

接下来的文章会被分为几个部分：第一章会介绍研究背景，选题意义以及主要研究内容；第二章将会介绍基础的机器学习聚类算法 K-均值算法，均值漂移算法，中心点偏移算法的工作原理；第三章会介绍问题定义，评价指标以及深度学习方法深度残差网络算法和机器学习聚类算法结合下的聚类原理；第四章会分别介绍基于不同距离计算方式下的聚类算法和与深度残差网络算法结合后的聚类结果；第五章介绍全文总结与未来的展望。

第一章 绪论

1.1 研究背景以及选题意义

随着计算机技术的快速发展，图像聚类作为计算机视觉领域中的一个重要研究方向，在日常生活中的应用领域也越来越广泛。近年来，随着深度学习算法的不断优化和普及，图像聚类在人脸识别、垃圾智能分类、辅助医疗诊断、癌症治疗等领域中的应用也日益增多。

在人脸识别领域，图像聚类算法被用来对人脸图像进行特征提取和分类，从而帮助计算机识别出人脸。垃圾智能分类领域则是将图像聚类算法应用于垃圾分类中，通过分析垃圾图像的特征，帮助人们更加准确地进行分类。在辅助医疗诊断领域，图像聚类算法则被用来对医学图像进行分析和诊断，例如 CT 扫描、X 射线等，帮助医生更好地识别疾病和进行治疗。在癌症治疗领域，图像聚类算法则被用来对肿瘤进行定位和分类，帮助医生更好地进行手术和治疗方案的制定。这些应用领域的出现表明，图像聚类算法在实际应用中具有重要的作用和价值。随着技术的不断进步和创新，相信图像聚类算法在日常生活中的应用领域还将不断地扩展和深化。

在图像聚类方面，聚类算法的目的是将相似的图像聚集到一起，形成一个图像集合或图像库，以便于进行图像检索和分类等应用。传统的图像聚类方法主要基于人工设计的特征提取方法，而这些方法的效果有限，不能有效地提取出图像的本质特征，导致聚类结果不够准确。其中机器学习聚类算法技术在图像聚类方面的应用得到了快速发展。它通过对数据点或样本进行分组，将相似的数据点或样本聚集在一起，使得它们在同一组内具有相似的特征，而在不同组之间则具有较大的差异性。为此，越来越多的研究者开始探索基于机器学习的图像聚类方法譬如均值漂移算法 [1]，K-均值算法 [2]。Subbiah 和 Christopher [3]对传统的 K-均值算法进行改良，加入日志滤波技术应用于传统医疗行业，极大的辅助了医疗诊断。Su 和 Gao 对[4] 谱聚类加入了核密度估计思想，使其应用到高维数据的图像分类，提高了其在图像分类上的准确率。尽管如此，没有任何的相关研究是有关于均值漂移算法应用于图像聚类的，之后改良的中心点偏移算法 [5] 同理，它们多数用于图像分割，图像追踪领域而不是在图像聚类领域。同时，目前对于会用到距离计算的图像聚类机器学习算法，没有针对于不同距离计算方式对聚类结果影响的探讨。

值得一提的是，随着深度学习技术的发展，越来越多的研究者开始探索基于深度学习的图像聚类方法。这些方法通常是基于卷积神经网络等深度学习算法，通过对图像进行自动特征提取和表示学习，可以显著提高图像聚类的准确性和效率。譬如比较早的 ImageNet [6] 再到后面的 AlexNet [7] 以及 2017 年比较成熟的 DenseNet [8]，在图像聚类上的结果十

分出色。但是上述深度学习方法与传统机器学习方法的结合相对于主流算法来说研究相当较少。

因此本篇文章不仅仅探讨对于传统机器学习聚类算法在不同距离计算方式下的结果，同时也可以继续探讨通过深度学习初步提取特征后，不同距离计算方式效果的对比。

1.2 主要研究内容

该文章主要（1）探讨均值漂移算法，K-均值算法，中心点偏移算法在欧几里得距离，余弦距离方式下的聚类效果。（2）探讨引入深度学习聚类方法深度残差网络算法对原机器学习算法的提升效果。（3）探讨在引入深度残差网络算法基础上，欧几里得距离，余弦距离方式下的聚类效果。

第二章 相关方法介绍

2.1 K-均值算法原理介绍

K-均值算法是一种无监督的聚类算法。它可以将数据集分成 k 个不同的类别。其核心思想是通过最小化各个簇内数据点之间的距离来实现聚类。具体地，给定一个数据集和 k 个初始质心，K-均值算法通过迭代更新每个数据点所属的簇和簇的质心，直到收敛。其对于给定的样本集 $D = \{x_1, x_2, \dots, x_m\}$ ，K-均值算法可以表示为以下两个步骤：

1. 初始质心的选择：假设要分成 k 个簇，则需要选择 k 个初始质心 $c_1, c_2, c_3, \dots, c_m$ ，一种常见的选择方案是随机从数据集中选择 k 个数据点作为初始质心。

2. 迭代聚类过程：在每次迭代中，对于数据集中的每一个数据点 $x_i \in S$ ，根据它距离最近的质心（如图 2-1 中大圆点所示） $c_j(i)$ ，将它划分到簇 C_j 中。具体地，假设 C_j 表示包含所有被划分到第 j 个簇中的数据点，那么

$$C_j = \{x | c_j(i) = j\} \quad (2-1)$$

然后，对每个簇 C_j 重新计算其质心 c_j ，即

$$c_j = \frac{1}{|C_j|} \sum_{x \in C_j} x \quad (2-2)$$

这个过程持续迭代，直到簇不再有变化或达到最大迭代次数为止。




图 2-1 K-均值算法迭代图

K-均值算法可以用以下的目标函数进行表达：

$$J = \sum_{i=1}^k \sum_{x_j \in c_i} \|x_j - c_i\|^2 \quad (2-3)$$

其中， k 表示簇的个数， c_i 表示第*i*个簇的质心， x_j 表示数据集中的第*j*个数据点。目标函数的意义是所有簇内数据点到质心的距离的平方和。目标函数最小化的过程即为K-均值算法的核心过程。J越小则表示数据集样本中相似度越高。如果想要得到最小的J，但是直接求解并不容易，因此一般采用启发式算法解决。

2.2 均值漂移算法和中心点偏移算法原理介绍

2.2.1 均值漂移算法原理介绍

均值漂移算法（均值漂移）算法是一种基于密度的非参数聚类算法。其算法思想是假设不同簇类的数据集符合不同的概率密度分布，找到任一样本点密度增大的最快方向，样本密度高的区域对应该簇类的中心所在，这样样本点最终会在局部密度最大处收敛，且收敛到相同的局部最大值的样本点被认为是同一簇类的成员。同时，它不需要像K-均值算法那样预先指定簇的数量，而是通过数据点自适应地确定聚类的数量，并能够有效地应对非线性分布等复杂情况。

均值漂移算法通过核函数找密度高的区域，最常用的是高斯核。假设我们有大小为*n*的*d*维数据集 $\{x_i\}$ ，核函数*K*的带宽为参数*h*。

数据集的核密度估计：

$$f(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (2-4)$$

其中*K*(*x*)是径向对称函数（radially symmetric kernels），定义满足核函数条件的*K*(*x*)为：

$$K(x) = c_{k,d} k(\|x\|^2) \quad (2-5)$$

其中系数 $c_{k,d}$ 是归一化常数，使*K*(*x*)的积分等于1

由上节可知，数据集密度可以表示为公式（2-4），其梯度为：

$$\begin{aligned}
\nabla f(x) &= \frac{2c_{k,d}}{nh^{d+2}} \sum_{i=1}^n (x_i - x) g\left(\left\|\frac{x - x_i}{h}\right\|\right)^2 \\
&= \frac{2c_{k,d}}{nh^{d+2}} \left[\sum_{i=1}^n \right] g\left(\left\|\frac{x - x_i}{h}\right\|\right)^2 \left[\frac{\sum_{i=1}^n x_i g\left(\left\|\frac{x - x_i}{h}\right\|\right)^2}{\sum_{i=1}^n g\left(\left\|\frac{x - x_i}{h}\right\|\right)^2} - x \right]
\end{aligned} \tag{2-6}$$

其中：

$$g(s) = -k'(s) \tag{2-7}$$

上式的第一项为实数值，因此第二项的向量方向与梯度方向一致，第二项的表达式为：

$$m_h(x) = \frac{\sum_{i=1}^n x_i g\left(\left\|\frac{x - x_i}{h}\right\|\right)^2}{\sum_{i=1}^n g\left(\left\|\frac{x - x_i}{h}\right\|\right)^2} - x \tag{2-8}$$

上式的含义就是均值漂移向量。由上式推导可知：均值漂移向量所指的方向是密度增加最大的方向（如图 2-2 所示）。




图 2-2 均值漂移算法迭代过程

因此，均值漂移算法流程为：

- (1) 计算每个样本的均值漂移向量 $m_h(x)$
- (2) 对每个样本点以 $m_h(x)$ 进行漂移，即：

$$x_i = x_i + m_h(x_i) \tag{2-9}$$

(3) 重复 (1) (2)，直到样本点收敛，即：

$$m_h(x) = 0 \quad (2-10)$$

(4) 收敛到相同点的样本点被认为是同一簇类的成员

2.2.2 中心点偏移算法原理介绍

中心点偏移算法来源于均值漂移算法。与均值漂移算法相似，中心点偏移算法也是一种应用核密度估计的非参数搜索聚类算法，是基于中心点的加权来估计局部的近似梯度，通过计算漂移从而向数据密度更大的区域偏移。但是它和均值漂移算法不同的是，中心点偏移算法不需要均值向量的定义，只需要定义有效的样本点距离度量。两者最大的不同是均值漂移算法算法中计算漂移是找均值漂移向量的位置，中心点偏移算法算法计算漂移寻找的是距离偏移最近的数据集里的点。

均值漂移算法可以表示如下：

$$y_{k+1}^{mean} = \underset{y}{\operatorname{argmin}} \sum_i \|x_i - y\|^2 \psi\left(\left\|\frac{x_i - y_k}{h}\right\|\right)^2 \quad (2-11)$$

中心点偏移算法可以表示如下：

$$y_{k+1}^{medoid} = \underset{y \in x_i}{\operatorname{argmin}} \sum_i \|x_i - y\|^2 \psi\left(\left\|\frac{x_i - y_k}{h}\right\|\right)^2 \quad (2-12)$$

可以看到，均值漂移算法选择最小化函数 (2-11) 的位置 y ，而中心点偏移算法选择最小化函数 (2-12)。具体的数据样本点选择差异具体如图 2-3 所示：

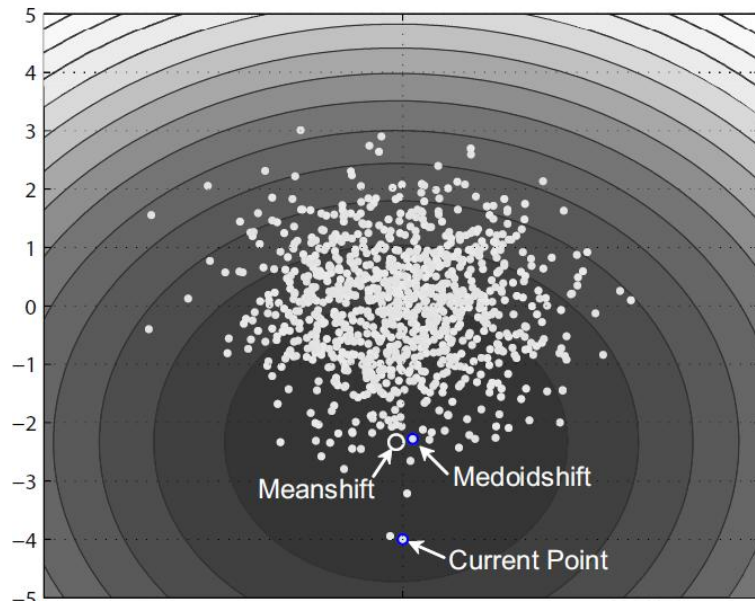


图 2-3 均值漂移算法根据向量漂移，中心点偏移算法根据点去移动

其余的迭代过程和均值漂移算法类似。

2.3 深度残差网络算法原理介绍

许多深度学习方法随着网络的加深，虽然信息获取的越来越多，而且特征也越来越丰富。但是实际上随着网络的加深，优化效果反而越差，测试数据和训练数据 3 的准确率反而很低。这是因为由于网络的加深会造成梯度爆炸和梯度消失的问题。2015 年的时候，何凯明等人根据局部聚合向量和高速网络的思想提出了一个新的网络结构 - 深度残差网络算法 [9]，来解决梯度爆炸和梯度消失的问题。

深度残差网络算法在深度学习方法应用中非常的广泛，尤其是在深度学习领域，它的本质是一种残差网络，也可以理解为一个子网络，这个子网络经过堆叠，可以构成很深的网络。其结构可以简单表示为如下：




图 2-4. 残差学习示意图

在传统的深度神经网络中，每个层都被看作是对前一层的输入进行非线性函数映射得到输出的过程，如下所示：

$$H(x) = F(x) + x \quad (2-13)$$

其中， $F(x)$ 表示当前层的网络映射， x 为前一层的输出。通过上式可以获得输出 $H(x)$ 。深度残差网络算法进一步推广了上式，成为：

$$H(x) = F(x) + x \quad (2-14)$$

其中 $F(x)$ 表示当前层的网络映射, x 为当前层的输出。通过这种残差学习的方式, 深度残差网络算法网络通过跨层的残差连接实现了捕捉数据之间关系的能力。

2.4 深度残差网络算法和聚类算法结合介绍

传统机器学习在进行图像分类的时候会有很多的局限性, 譬如均值漂移算法无法像 K-均值算法那样直接用于图像聚类。比较常用的做法是将图像数据展开为一维数据之后, 均值漂移算法才可以使用。但是如果图像数据被展开到一维后, 其图像特征很难被提取到, 因此比较好的做法是与深度学习结合起来。然而深度学习里面比较好的一种特征提取方法就是深度残差网络算法。

当将深度残差网络算法和传统机器学习聚类方法结合在一起时, 通常是为了进一步提高图像分类的准确性和效率。具体来说, 深度残差网络算法是一种深度残差网络, 其通过使用残差连接来克服深度网络训练中的梯度消失问题, 从而提高了网络的深度和泛化能力。与传统机器学习聚类方法结合时, 深度残差网络算法可以用来提取图像特征, 然后将这些特征传递给聚类算法。一种常见的结合方法是将深度残差网络算法的输出特征传递给 K-均值算法聚类算法。在深度残差网络算法和 K-均值算法结合的过程中, 深度残差网络算法被用来提取图像特征, 这些特征被传递给 K-均值算法, 以确定图像的类别。具体来说, 深度残差网络算法的输出特征被作为 K-均值算法的输入特征, K-均值算法将这些数据点分为 K 个簇, 每个簇对应于一个图像类别。通过这种方式, 深度残差网络算法可以为聚类算法提供更准确的特征表示, 从而提高图像分类的准确性。除了 K-均值算法聚类算法之外, 还有其他传统机器学习聚类方法可以与深度残差网络算法结合使用, 例如均值漂移算法聚类算法和社区发现算法。这些方法都可以用于将深度残差网络算法提取的特征表示转换为聚类簇。

第三章 问题定义及实验结果分析

在这一章里面，我们先介绍问题的定义以及评价指标，接着我们介绍实验所用的数据集，实验整体的设置，以及参数的选择。然后我们分别介绍基于欧式，余弦距离下的均值漂移算法，中心点偏移算法，K-均值算法在数据集上的结果，在以上基础上继续介绍基于深度残差网络算法特征提取后，三种算法基于欧式，余弦距离下的结果，最后我们将结果对比进行讨论分析得出结论。

3.1 问题基本定义和数据处理

假设给定一大组彩色图片，对于像素大小高宽无要求。由于均值漂移算法无法直接处理高维数组，因此为了适应均值漂移算法特点照片都会统一设定大小至(224,224,3)的高维数组格式，然后将其平铺到高维150528维（ $224 \times 224 \times 3$ ）的向量。然后将此高维向量分别送入均值漂移算法，K-均值算法，中心点偏移算法中进行训练最后得到训练结果。

与深度残差网络算法50结合时，首先将图像数据改成 $224 \times 224 \times 3$ RGB数据，转化为张量之后送入深度残差网络算法-50训练，得到提取完特征的 $224 \times 224 \times 3$ 的一维向量，此时再送入机器学习聚类算法进行聚类并得到标签分配。

经过如上步骤后，最后每个图片都会归类于它的簇中心，但不会被分给一个具体的动物类别。

3.2 评价指标

传统的准确率等评价指标对于聚类的效果评估十分不科学，因为在这个多分类问题中，是无法指定图片最后被分为哪一个具体的类。比如说海豚图片，通过算法计算后无法提供一个动物类别指标，而是和其它动物图片一起被分到没有类别的簇里。由于数据都是有真实标签的，面对这种问题时归一化互信息是一个十分有效的评估手段。因此本文采用了归一化互信息来评价算法在图像聚类上的效果。

3.3 数据集介绍

动物（也称为后生动物）是动物界中的多细胞、真核生物，同时他们的外形具有明显的区别易于区分。因此在这个工作中，图像数据都采用动物图片，方便算法进行聚类。Animals90动物数据集 [10]，收集于Google Image，在动物图片数据集上具有一定权威性，非常适合用于图像聚类算法。它包含90个不同类别动物，约有5400张动物图像，每种类含有60张图片。所有照片都已经按照其所属类别存放于各自的文件夹下。动物种类包括常见的类别，如羚羊，獾，蝙蝠，熊，蜜蜂，甲虫，野牛，公猪，蝴蝶，猫，毛虫，黑猩猩等。

在实验中为了确保随机性，在选取动物类别的时候并没有选择全部的动物，而是随机选择了其中几种。实验随机选择的数据包含了羚羊，鸭子，奶牛，海豚每种有60张图片，同时加入了噪声，选取了狗和猴子类别，每种只有6张图片。总共合在一起有252张照片。

3.4 实验设置以及参数介绍

在整个实验模块中，由于评价指标采取的是归一化互信息，因此每个算法的参数都会被调为最优，来保证最终实验结果的可参考性。其中均值漂移算法和中心点偏移算法是调整半径的大小，K-均值的聚类中心个数的参数最优默认为数据集里动物的类数。在实验中实验整体分为二大模块，第一个实验模块是基于余弦距离的均值漂移算法，中心点偏移算法，K-均值与基于欧式距离的均值漂移算法，中心点偏移算法，K-均值之间的比较，第二个实验模块在深度残差网络算法提取图像特征之后，基于欧式距离以及余弦距离的均值漂移算法，中心点偏移算法，K-均值在此基础上完成聚类，并对比其实验结果。

3.5 基于余弦，欧式距离的算法结果比较

3.5.1 参数设置

本小节模块整体分为两个实验，一个是基于欧几里得距离的实验，另外一个是基于余弦距离的实验。其中欧几里得距离实验需要调整的参数（K-均值算法的K最优解默认是类的个数），均值漂移算法，中心点偏移算法需要调整半径大小（由于算法时间复杂度很高调参过程就不予展示只给出最优解）。余弦实验中均值漂移算法和中心点偏移算法需要调整的也是半径大小，但是由于是余弦，其半径大小的值处于（0,1）之间。

为了不占用太多空间，仅仅在欧几里得距离实验中展示图片聚类结果。其余参数设置以及归一化互信息值如表3-1，表3-2所示。

3.5.2 实验结果展示以及分析

欧几里得距离实验：

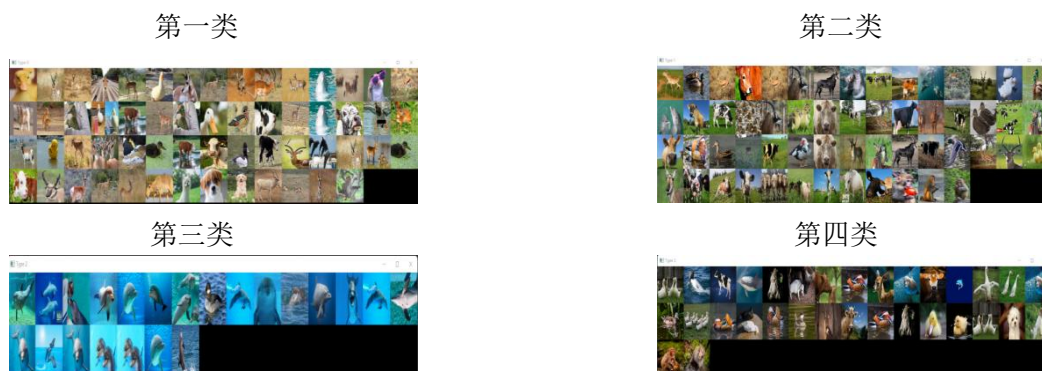




图 3-1 K-均值算法欧几里得距离聚类结果



图 3-2 均值漂移算法欧几里得距离聚类结果



图 3-3 中心点偏移算法欧几里得距离聚类结果

由图 3-1，图 3-2，图 3-3 可见，在欧几里得距离实验中，K-均值算法的分类结果是比较接近真实类个数的，同时其划分结果相比较于其它两种算法而言更加平均。均值漂移算法的

结果就与真实结果极大不符合，只划分了一个类。相比较而言中心点偏移算法的结果类数比均值漂移算法合理不少，但是其划分的结果可以看到毫无关联性，相对于 K-均值算法而言依然结果比较差。

表3-1 欧几里得距离实验参数设置以及归一化互信息值

算法名字\结果以及参数	参数（类个数/半径）	归一化互信息结果
K-均值算法	6	0.060
均值漂移算法	4100	0.014
中心点偏移算法	3950	0.059

余弦实验距离：

表 3-2 余弦距离实验参数设置以及归一化互信息值

算法名字\结果以及参数	参数（类个数/半径）	归一化互信息结果
K-均值算法	6	0.089
均值漂移算法	0.46	0.018
中心点偏移算法	0.7	0.069

通过实验结果表3-1表3-2可以发现，K-均值算法在一维图像数据聚类上要明显优于均值漂移算法和中心点偏移算法，不管是在欧氏距离还是余弦距离，K-均值算法分别以0.060, 0.089位居第一。同时中心点偏移算法表现结果稳定强于均值漂移算法，譬如表3-2余弦距离里中心点偏移算法的0.059高于均值漂移算法的0.018。可能由于是在高维数据中，中心点偏移算法所迭代的点比均值漂移算法更稳定。值得一提的是，余弦距离计算方式相较于欧氏距离计算方式在三个算法中都提升了归一化互信息值，并且提升幅度相对于欧式距离来说很大。明显可见在一维图像数据聚类中，余弦距离要明显优于欧几里得距离。

3.6 基于深度残差网络算法特征提取后的余弦，欧式距离的算法结果比较

3.6.1 参数设置与实验结果

本小节模块整体同样分为两个实验，一个是基于欧几里得距离的深度残差网络算法实验，另外一个是基于余弦距离的深度残差网络算法实验。深度残差网络算法利用的是已经预训练好的深度残差网络算法-50模型，在本次实验中为了统一，网络设置都是用的：一层卷积，批量归一化，relu激活函数，池化再加四层隐藏层。其余算法参数设置和3.5节类似。具体参数设置以及归一化互信息值如表3-3，表3-4所示。

表3-3 深度残差网络算法中欧几里得距离实验参数设置以及归一化互信息值

算法名字\结果以及参数	参数（类个数/半径）	归一化互信息结果
K-均值算法+ 深度残差网络算法	6	0.305
均值漂移算法+ 深度残差网络算法	310	0.049
中心点偏移算法+ 深度残差网络算法	270	0.093

表3-4 深度残差网络算法中余弦距离实验参数设置以及归一化互信息值

算法名字\结果以及参数	参数（类个数/半径）	归一化互信息结果
K-均值算法+ 深度残差网络算法	6	0.315
均值漂移算法+ 深度残差网络算法	0.41	0.054
中心点偏移算法+ 深度残差网络算法	0.64	0.095

3.6.2 讨论分析

通过表 3-3，表 3-4 结合表 3-1，表 3-2 的结果可以看到，引入深度学习深度残差网络算法方法后对结果都有明显性的提升，尤其对于 K-均值算法，从原来的 0.089 提升到 0.305。同时结合深度残差网络算法方法之后，余弦距离的表现依然稳定高于欧几里得距离，但是提升没有那么明显，譬如均值漂移算法从 0.049 提升到 0.054。

第四章 总结与展望

本篇文章探讨了基于不同距离计算方式的图像聚类效果，同时也探讨了引入深度学习深度残差网络算法后对图像聚类效果的影响。可以总结的是（1）余弦距离计算方式在一维图像聚类中优于欧几里得距离计算方式（2）引入深度学习深度残差网络算法之后对于聚类效果提升显著（3）引入深度残差网络算法之后余弦距离相较于欧几里得距离，聚类效果比没引入深度残差网络算法时提升效果差。

因此，对于未来还可以继续展望完善的点有：

- （1）继续比较曼哈顿，轮廓系数等计算方式
- （2）降低调参粒度，把步长缩的更小，尽可能保证全局最优解

参考文献

1. D. Comaniciu and P. Meer, "Mean shift: a robust approach toward feature space analysis," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 24, no. 5, pp. 603-619, May 2002, doi: 10.1109/34.1000236.
2. MacQueen, J.. "Some methods for classification and analysis of multivariate observations." (1967).
3. Subbiah, Balasubramanian, and Seldev C. Christopher. "Image classification through integrated K-均值算法 algorithm." International Journal of Computer Science Issues (IJCSI) 9.2 (2012): 518.
4. Su Y, Gao L, Jiang M, Plaza A, Sun X, Zhang B. NSCKL: Normalized Spectral Clustering With Kernel-Based Learning for Semisupervised Hyperspectral Image Classification. IEEE Trans Cybern. 2022 Nov 17;PP. doi: 10.1109/TCYB.2022.3219855. Epub ahead of print. PMID: 36395126.
5. Y. A. Sheikh, E. A. Khan, T. Kanade.: Mode-seeking by Medoidshifts. In: 2007 IEEE 11th International Conference on Computer Vision, Rio de Janeiro, Brazil, pp. 1-8, doi: 10.1109/ICCV.2007.4408978 (2007).
6. Deng J, Dong W, Socher R, Li L-J, Li K, Fei-Fei L. 2009. ImageNet: a large-scale hierarchical image database. In IEEE Conf. on Computer Vision and Pattern Recognition, Miami, FL, pp. 248 - 255. IEEE. (10.1109/CVPR.2009.5206848) - DOI
7. Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. 2017. ImageNet classification with deep convolutional neural networks. Commun. ACM 60, 6 (June 2017), 84 - 90. <https://doi.org/10.1145/3065386>
8. Huang, G., Liu, Z., van der Maaten, L., and Weinberger, K. Q., "Densely Connected Convolutional Networks", arXiv, 2016. doi:10.48550/arXiv.1608.06993.
9. K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition," 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 770-778, doi: 10.1109/CVPR.2016.90.
10. Animal90 数据集,
<https://www.kaggle.com/datasets/iamsouravbanerjee/animal-image-dataset-90-different-animals>

致 谢

光标随着键盘敲打被驱赶到此处，不停闪烁，仿佛在催促我快点给论文画上句号。霎时间大脑一片空白，跟光标一样，我也在被驱赶，被致谢驱赶到了本科阶段的边缘。挣扎着想用拖延去挽留这毫无意义的仪式感。最终还是选择夺回主动权，敲打键盘，推动着光标向前，给致谢画上一个句号，以及未完待续的省略号。

弹指一挥，开始在19年秋天的这个荒诞，可笑，疯狂，却仍然轰烈浪漫的故事即将结束。我的故事能够走到这一步，想要感谢的人很多。

首先感谢指导老师路永钢教授，感谢他愿意给我一个机会让我接触到聚类这个方向。对毕设的指导意见也非常细致，从最开始的选题到最后的修改，离不开他的悉心教导。祝路老师今后身体健康，工作顺利。

感谢父母给我生命，将我养大成人。从小到大父母在不过分的物质方面都会满足我，同时也会想方设法丰富我的生活。小时候的我胆小内向，当时让你们多费心了。感谢你们一直在保护我，支持着我。家里发生了什么事情也都是先关心我的行程安排，尽量不影响我的学习生活；而我做的什么决定你们也会无条件支持我。谢谢你们，祝我们一家三口今后每个人都会越来越好。

感谢每一位曾经帮助过我的学长学姐，老师。很多时候有生活上的帮助，也有那些技术细心的指点，到能很快上手操作都离不开他们的帮助。同时更有许多人生的指点，支撑着我现在的道路和选择。谢谢各位学长学姐，老师！

感谢我的室友，从一开始的拄着拐杖，坐着轮椅时对我生活的，学业上的照顾到平时互相尊重到点睡觉，没有任何的吵闹声，甚至于平日里的互帮互助。感谢你们的包容和互相理解，虽然以后可能很难相见了，但是也祝福你们之后的道路越来越顺。

还要感谢四年以来一直陪伴着我的高中同学，虽然你们大部分时间同我都隔着网线，但还是感谢你们这四年不厌其烦地见证着我的欢笑与泪水，在这里就不一一点名了，自行对号入座。今后的相聚可能以年为单位了，但还是永远期待下一次见面，期待见到还是那么善良友好帅气美丽的大家。无论面前脚下的路怎么样，祝我们前程似锦，未来可期。

感谢自己。感谢自己的每一次勇敢，自己的勇敢同时接纳了自己的胆小，让胆小随后滋生出新的勇敢；感谢自己的每一次执着，自己的执着允许自己有时放弃，随后区分出那些值得自己执着的人与事；感谢自己的感性，感性的存在时刻提醒着自己理性也不失一种选择。

悟已往之不谏，知来者之可追。好好坏坏真真假假都已经过去了，感谢遇到的所有，无论好坏.....

兰州大学本科毕业论文

基于不同距离计算的图像聚类分析

毕业论文（设计）成绩表

导师评语

该论文利用 mean-shift 对图像进行了聚类研究，具有一定的理论和应用价值。论文写作达到了本科论文的写作要求。

建议成绩

良

指导教师（签字）

路永钢

答辩委员会意见

经答辩小组一致讨论，该论文通过答辩，成绩为良。

答辩委员会负责人（签字）

路永钢

成绩

良

学院（盖章）

